

Qué es Claude: modelos, productos y su lugar frente a otros LLM

Claude Certified Developer, Foundation (CCDV-F) · Masterclass UST

ES

Sesión 1 de 12 · Notas en español (es-ES)

Definición central de Vijay: **Claude es la familia de modelos de IA de Anthropic más las aplicaciones que se apoyan en esos modelos.** Anthropic es una empresa de investigación y tecnología de IA fundada en 2021 (el formador la situó en la estela de la investigación de la era OpenAI). Los productos en los que hacéis clic son clientes. Los modelos (Haiku, Sonnet, Opus y otros nombrados en clase) son los servidores. Casi toda característica posterior—Cowork, Code, herramientas, RAG—solo encaja si mantenéis esa separación.

Cliente–servidor: productos frente a modelos

Chat, Cowork, Claude Code y las apps que llaman a la API son **clientes**. Presentan la UI, guardan el historial, adjuntan carpetas y deciden cuándo llamar a una herramienta. El LLM es un **servidor sin estado**: recibe una petición, devuelve una respuesta y no guarda sesión en el servidor. Por eso funciona el escalado horizontal y los proveedores pueden poner una postura de *retención cero de datos* en el SLA del modelo.

Si Claude Chat «recuerda» el hilo de ayer, esa memoria vive en el *cliente* (historial, proyecto, interruptor de memoria de Cowork). En el turno siguiente el cliente reenvía el contexto que el modelo necesita. Confundir memoria del cliente con memoria del modelo es una trampa habitual en el diseño de conversaciones.

NOMBRES EN EL AULA DE AGOSTO DE 2026

Vijay enumeró Haiku, Sonnet, Opus y nombres adicionales que salieron en el selector en vivo (incluido «Fable» / similar por ASR). Tratadlos como *ilustrativos de la familia*. Confirmad IDs, tamaños de contexto y qué SKU habilita vuestra organización en la [página de modelos](#) vigente.

Transformers, modelos generativos y coste de entrenamiento

El formador situó todos los modelos de clase Claude en la arquitectura **transformer** introducida por Google Brain en 2017. Son modelos **generativos**: producen contenido (un artículo, una función, un plan), no solo una etiqueta discriminativa verdadero/falso. Entrenar no es un cuaderno de fin de semana. Analogía de Vijay: entrenar un LLM de frontera puede costar más en cómputo que «enviar un cohete a la luna»; su ejemplo de la era GPT-4o era del orden de más de 100 millones de USD, petabytes de datos y grandes clústeres GPU. No vais a ajustar un LLM completo al vuelo en un sprint de UST.

Qué vieron realmente los pesos

Para concretar «el modelo ya sabe programar», recorrió una mezcla estilo Llama-13B pública: Common Crawl / CCNet (páginas web archivadas durante años), texto web con consentimiento tipo C4, GitHub (código abierto, Kubernetes, Java, Python, .NET), Wikipedia, libros, arXiv, Stack Exchange. El punto para desarrolladores: el modelo ha visto un corpus público enorme. No ha visto el directorio de empleados de

UST ni la versión inédita de LangChain de la semana pasada, salvo que lo aportéis con herramientas, MCP, RAG o (caro) entrenamiento a medida.

Fecha de corte, multimodal y tool calling

Tras una tanda larga de entrenamiento (citó 6–8 meses como ciclo típico de frontera), el modelo se publica con una **fecha de corte de conocimiento**. En la demo de Chat del 3 de agosto de 2026, Claude respondió que había sido entrenado hasta hacia enero de 2026—un hueco de seis meses que el propio modelo señaló. Lo posterior al corte no está «en los pesos». El tiempo, la bolsa y la página de Confluence del martes exigen **tool calling** (llamada a funciones): el modelo planifica una llamada a una API REST, Lambda, Azure Function, búsqueda web o conector; el cliente la ejecuta; vuelve JSON; el modelo escribe la respuesta para el usuario.

- **Multimodal:** Vijay afirmó que los modelos Claude de este curso son multimodales—pueden tomar texto, imágenes y (en el debate) otros medios—no «modelos de lenguaje» solo texto. Las pilas open source aún pueden ofrecer SLM/LLM solo texto.
- **Tool calling en todos los Claude de clase:** es la característica que hace que Chat, Cowork y Code sean *agentic* y no una compleción de un solo disparo.
- **No volquéis toda la documentación en CLAUDE.md:** un debate largo advirtió que meter la documentación completa del fabricante en markdown mata tokens. Preferid MCP, RAG o búsqueda de docs puntual.

Cómo obtenéis datos que los pesos nunca vieron

Cuando los SDK y las bibliotecas se mueven más rápido que el corte (el ejemplo LangChain 0.46 frente a 1.2), Vijay enumeró opciones por realismo empresarial:

1. **No reentrenéis el LLM a diario** por el tiempo o la bolsa. Esa palanca es la incorrecta.
2. **Búsqueda web / de documentación como herramienta** — funciona, gasta tokens, sigue siendo el valor por defecto para «cuál es la API actual».
3. **MCP (Model Context Protocol)** — la forma estándar de enchufar datos de terceros y del fabricante al cliente; preferible si mañana cambiáis Figma por Adobe XD sin reescribir la app.
4. **RAG** — vuestro propio corpus indexado (docs fijados a una versión). Pre-poblado, no es una consulta en vivo. Útil a escala de organización si la versión está estandarizada tras la revisión de vulnerabilidades.
5. **Entrenamiento a medida / continuado** — caro; reservó el lenguaje de «entrenar al vuelo» para modelos de lenguaje *pequeños* (estilo SageMaker), no para LLM de frontera.

Inferencia, tokens y alucinación (avance)

Como el servidor no tiene estado, **inferencia** significa: enviáis todo el contexto que el modelo necesita, cada vez, hasta una **ventana de contexto** (cifras de aula: ventanas de clase ~200k, con opción de 1M en algunos SKU de Sonnet—verificad en vivo). Los tokens son específicos del modelo (demostró un tokenizador; «hi» frente a un párrafo no es un recuento fijo de caracteres). La facturación suele ser tokens de entrada + tokens

de salida; algunas pilas también facturan tokens en caché. Claude Chat en la demo empresarial se planteó como entrada/salida; la caché de prompts aparece más adelante en el temario.

Alucinación en su historia didáctica: la palabra «bank» puede ser un banco, la orilla de un río o un banco de sangre si el prompt es impreciso. Se corrige con rol, tarea, restricciones y **skills / instrucciones de sistema** (invocadas con barra en Claude)—sabiendo que esas líneas extra *también* consumen tokens en cada turno. El capítulo 04 vuelve a los hábitos de estudio; los módulos 8–9 vuelven a la técnica de prompting.

Dónde se sitúa Claude frente a «otros LLM»

Vijay comparó la familia con el chat estilo ChatGPT y con GitHub Copilot en su evolución de asistente en línea a agente. El contraste no es de marca; es de arquitectura: los productos Claude son clientes sobre modelos Anthropic con uso de herramientas de primer nivel, Cowork como espacio agentic local y Claude Code como agente que puede ejecutar comandos—no un autocompletado de un solo archivo. Los créditos de Copilot y la mezcla de modelos se describieron como muy cambiantes (mencionó un cambio de facturación de Copilot en julio de 2026). De nuevo: las respuestas del examen deben usar el lenguaje de producto vigente de Anthropic, no una queja de proveedor.

PRIMAN LOS DOCS SOBRE LOS IDS DE MODELO DEL AULA

Tamaños de contexto (272K frente a 1M), deslizadores de esfuerzo y SKU de «thinking» / pensamiento extendido se demostraron en vivo. No coincidirán con el cuadernillo del examen si Anthropic los ha renombrado. Usad **modelos** y **pensamiento extendido**.

Documentación oficial

- **Resumen de modelos**

<https://docs.claude.com/en/docs/about-claude/models>

Familias, ventanas de contexto y qué capacidades (visión, thinking) van con cada ID.

- **Resumen de la API**

<https://docs.claude.com/en/api/overview>

Cómo consumen las aplicaciones los mismos modelos que los clientes con interfaz.

- **Uso de herramientas**

<https://docs.claude.com/en/docs/agents-and-tools/tool-use/overview>

Llamada a funciones: el mecanismo detrás de búsqueda web, conectores y agentes.

- **MCP**

<https://docs.claude.com/en/docs/agents-and-tools/mcp>

Patrón estándar de conectores que Vijay contrastó con herramientas ad hoc y RAG.

- **Política de uso**

<https://www.anthropic.com/legal/usage-policy>

Las conversaciones empresariales sobre retención y uso aceptable empiezan aquí.