

Ventana de contexto, sesiones y por qué no son el límite de uso

Claude Certified Developer, Foundation (CCDV-F) · Masterclass UST

ES

Sesión 3 de 12 · Notas en español (es-ES)

Dentro de Claude Code, Vijay dedicó un tramo largo a `/context` porque el alumnado sumaba el **porcentaje de uso** de Chat al **espacio libre de la ventana de contexto** y se asustaba cuando las cifras no cuadraban. Son medidores distintos. Confundirlos os costará dinero e ítems de examen.

Ventana de contexto: lo que puede llevar una petición

La ventana de contexto es el tope de cuánto texto (tokens) *puede enviar el cliente al modelo en un turno*, incluidas instrucciones de sistema, herramientas, skills, historial y vuestro mensaje nuevo. En clase, los modelos por defecto estaban en una ventana de **clase ~200k** (repetía 272K); algunos SKU de Sonnet ofrecían **1M** vía `/model` (p. ej. «Sonnet 1 million»). Releed siempre la página de modelos vigente. Un volcado de 100 MB no cabe entero; el producto carga lo que puede.

`/context` mostró una sesión capaz de 1M con ~967K aún direccionables, ya parcialmente comidos por system prompt, tools, skills, messages y el **búfer de auto-compact**. El espacio libre (~893K en la demo) es lo que aún podéis empujar. El chip de «uso» 4 % / 39,8K en la misma UI *no* estaba pensado para sumar con ese libre hasta 967K: parte del resto es conversación ya en el hilo, redondeo y otros cubos. Vyomkesh tenía razón en que la suma ingenua fallaba; la corrección de Vijay fue «no es el mismo contador».

Las sesiones llenan la ventana

Cada par usuario/asistente se queda en el cliente y se reenvía (servidor sin estado). Cinco comandos slash ya ocupaban sitio. Las skills que fijáis ocupan sitio cada turno salvo que las configuréis fuera. Los hilos largos **encogen el espacio libre**. Por eso la sesión 1 decía «abrid un chat nuevo» y por eso Code ofrece `/compact`: resumir el historial en una memoria más corta para que quepan los turnos siguientes. Si no hay diálogo suficiente, compact no hace nada («not enough messages»).

Auto-compact

`/config auto compact = true` (sintaxis de aula) dice a Code que compacte al llegar a la ventana y siga. El ajuste se escribe en el JSON de configuración de Claude (el capítulo siguiente cubre archivos de usuario / proyecto / local). Auto-compact es una estrategia de *contexto*. No recarga la barra de uso de Team.

Límites de uso: el otro medidor

Ajustes → Uso de Cowork/Chat es una **ventana de tasa/cuota** (reinicio de cinco horas + tope semanal en el esquema del 5 de agosto; los topes enterprise los pone el admin). Mide cómo de duro habéis pegado al servicio últimamente, no cuántos tokens quedan en el prompt actual. Los límites de tasa de API son un tercer plano (**docs**). No podéis hacer `/config` de un «gasta solo 2k tokens por turno» duro en Code; se

gobierna con prompting y sin meter enciclopedias en CLAUDE.md. /context es observabilidad, no un gobernador de presupuesto.

Medidor	Qué responde	Dónde lo visteis	Si da contra el muro
Ventana de contexto	¿Cabe la carga de este turno?	/context, selector 272K frente a 1M	Compact, sesión nueva, adjuntos más pequeños o un SKU de 1M
Barra de uso del producto	¿He agotado la asignación móvil de mi plan?	Escritorio Ajustes → Uso	Esperar el reinicio o pedir cuota a la org
Límites de tasa / facturación de API	¿Puede esta clave llamar a Messages ahora, y a qué precio?	Consola / errores de API	Backoff, Batches u otra clave/workspace

CUENTAS DE TOKENS DE AULA

272K, 1M, 967K libres, ilustraciones de 1M en cinco horas eran números de UI en vivo del 6 de agosto de 2026. Volved a **modelos** antes de citarlos en una respuesta escrita del examen.

Caché de prompts (nombradla, no la mezcléis)

La sesión 1 mencionó tokens en caché en algunas pilas; Claude Chat enterprise era «entrada + salida». La caché de prompts como función de API es un módulo posterior. Compact no es caché. El reinicio de uso no es caché. Si un enunciado dice «el mismo system prompt en 10k trabajos», pensad en cache/Batches, no en /compact.

Ejercicio de estudio

Escribid tres frases que podáis pegar en un escenario: (1) Empezaría una sesión nueva de Claude Code porque el hilo anterior había consumido la ventana. (2) No esperaría que Ajustes → Uso bajara tras compact. (3) Elegiría un modelo de 1M solo si el corpus recuperado lo necesita de verdad, porque esfuerzo y ventana cuestan.

Documentación oficial

- **Modelos (ventanas de contexto)**

<https://docs.claude.com/en/docs/about-claude/models>

Tamaños de ventana vigentes por ID.

- **Caché de prompts**

<https://docs.claude.com/en/docs/build-with-claude/prompt-caching>

La función de API que la gente confunde con compact y con las barras de uso.

- **Límites de tasa**

<https://docs.claude.com/en/api/rate-limits>

Medidor de API, no /context.

- **Resumen de Claude Code**

<https://code.claude.com/docs/en/overview>

Dónde se documentan ahora los comandos slash y las sesiones.

- **Workspaces**

<https://docs.claude.com/en/docs/build-with-claude/workspaces>

Agrupar proyectos frente a un solo hilo que se desborda.

Study notes distilled from the UST CCD Foundation masterclass. Prefer Anthropic's current docs over session anecdotes. Not official exam material.