

Elección de modelo, ventana de contexto y coste desde la API

Claude Certified Developer, Foundation (CCDV-F) · Masterclass UST

ES Sesión 7 de 12 · Notas en español (es-ES)

Tras el Hello Claude, Vijay listó modelos con el SDK (`client.models.list`), distinguió ids **alias** de **instantáneas con fecha** y recorrió precios: tokens de entrada, de salida y escritura/acierto de caché. También dedicó un tramo largo a la **temperature** (y top-k / top-p donde aún se exponen). El examen Foundation quiere que sepáis qué pagáis y por qué fijar una instantánea importa.

Listar modelos y leer ids

El SDK puede listar los modelos de vuestra clave, con id y nombre visible. En `model`: va el **id**. En el aula de agosto de 2026 las familias eran estilo Opus / Sonnet / Haiku (incluido «4.5» y cadenas fechadas, p. ej. una instantánea de noviembre de 2025 en el ejemplo oral). **Volved a comprobar la página viva de modelos antes del examen**: los ids y las ventanas se mueven.

Alias frente a instantánea fechada

Un alias (en clase: «genérico» / el último de una línea como Haiku 4.5) sigue la instantánea compatible más nueva. Un id completo con fecha fija el comportamiento. Regla de Vijay: si evaluasteis prompts contra una instantánea, **no os montéis en silencio en el alias** — una instantánea nueva puede «romper» la aplicación de un día para otro. Rajesh preguntó por caducidad / SLA: los catálogos de empresa publican modelos soportados; salir de un id retirado es una migración de software normal (podéis automatizar un agente que suba ids; no es reescritura mágica).

COMODIDAD DEL ALIAS FRENTE A PRODUCCIÓN

Alias = menos toil, más sorpresa. Id fechado = reproducibilidad para evals. Al examen le gusta ese contraste.

Tres «ventanas» en lenguaje de clase

Idea	Lo que dijo Vijay	Cómo pensarlo
Contexto de entrada	Del orden de 272K o 1M de tokens según modelo; los ids de 1M suelen llevar marca 1M	Cuánto system + messages + archivos podéis enviar
Salida / max_tokens	Techo de tokens generados; demos con 1024; llegar al techo trunca	No es la misma cifra que la ventana de entrada
Caché de prompts	Capacidad y precio aparte para guardar un prefijo en el servidor minutos/horas	Módulo 09; no confundir con medidores de Chat Pro

Las cifras 272K / 1M eran didácticas. Los modelos reales varían (algunos 200K, otros más). Fuente de corrección: **modelos**.

max_tokens y stop_reason

No podéis saber de antemano la longitud exacta de salida. Elegid max_tokens según el trabajo (clasificación corta frente a informe largo). Si el modelo aún tiene más que decir, la generación **para en seco** y stop_reason refleja el límite de tokens. El tamaño de entrada lo controláis vosotros; el de salida, max_tokens (y las secuencias de parada). El «1024 de base» es un valor de demo, no un mínimo de plataforma — leed los defaults actuales de la API.

Modelo mental de precio (API, no Claude Pro)

La API factura por millón de tokens, con **tarifas distintas** para entrada y salida (la salida se describió mucho más cara, p. ej. una diapositiva ~10 \$ entrada frente a ~50 \$ salida por millón en una fila tipo Opus — *ilustrativo, no para memorizar*). La escritura de caché a ~5 minutos frente a ~1 hora tenía precios de escritura más altos; los aciertos de caché se describieron del orden de 1 \$ por millón en esa diapositiva. Chatear con un PDF de 1M de tokens en cada turno vuelve a pagar entrada; cachear el prefijo del documento es la optimización. **Claude Pro a ~20 \$/mes con refresco de 5 horas es otro producto** — no apliquéis la aritmética de tokens de API a ese plan.

- Entrada, salida, escritura de caché y acierto de caché son contadores separados.
- Una sesión en Chat ≠ la vida de la clave de API. Se factura el uso contra la clave, no «una ventana de chat».
- Los sitios de tokenizador de terceros no son Anthropic; Vijay usó uno solo para mostrar que la tokenización depende del modelo.

Temperature, top-k, top-p

Temperature en clase: rango **0 a 1** (se corrigió a sí mismo). **0** = más determinista / «específico»; **1** (default del SDK que citó como 1.0) = más diverso / creativo. Demo de ideas de película: a 0 se quedaba en una órbita similar; a 1.0 saltaba de género. Temperatura baja para extracción y búsqueda en contexto; alta para lluvia de ideas. Más temperature es *creatividad*, no automáticamente «alucinación», aunque un prompt flojo y temperature alta divagan más.

Esbozó transformers: los embeddings convierten texto en vectores; la atención usa key/query/value; bloques apilados proponen distribuciones del siguiente token. **Top-k** deja solo k candidatos; **top-p** (núcleo) filtra por probabilidad acumulada. Matiz importante: **los Claude más nuevos a menudo ocultan o ignoran top-k/top-p** y pueden exponer solo temperature. Los Haiku de aquella semana quizá aún los aceptaran. Confirmad en la ficha de API del modelo.

Qué va en cada petición

REST sin estado: cada llamada lleva id de modelo, messages, system (si se usa), temperature, max_tokens, etc. No podéis «fijar system una vez» en el servidor. La caché es la función que abarata reutilizar un prefijo grande — no una sesión oculta.

PRECIOS Y VENTANAS CADUCAN

Cualquier cifra en dólares o ventana 272K del 17 de agosto de 2026 es una instantánea. Examen y producción: precios y fichas de modelo actuales en docs.claude.com.

Documentación oficial

- **Modelos**

<https://docs.claude.com/en/docs/about-claude/models>

Ids, alias, ventanas de contexto, política de instantáneas.

- **Messages API**

<https://docs.claude.com/en/api/messages>

model, max_tokens, temperature, stop_reason, usage.

- **Caché de prompts**

<https://docs.claude.com/en/docs/build-with-claude/prompt-caching>

TTL de caché y contabilidad de tokens (tratamiento completo en M09-C04).

- **Límites de tasa**

<https://docs.claude.com/en/api/rate-limits>

Techos de caudal distintos del precio por token.

Study notes distilled from the UST CCD Foundation masterclass. Prefer Anthropic's current docs over session anecdotes. Not official exam material.